



PROGETTO DI MACHINE LEARNING

PREVISIONE DEPOSITI BANCARI

Un modello di machine learning per capire, tra i clienti contattati,
chi sottoscriverà un deposito a termine.

Cerea Gianluca · Andrea Morlotti

Dataset: archive.ics.uci.edu/dataset/222/bank+marketing



IL CONTESTO

Il progetto in breve

Una banca portoghese ha contattato migliaia di clienti per proporre un deposito a termine: vogliamo prevedere chi accetterà.

45.211

contatti analizzati

17

Variabili analizzate + target



Anagrafica cliente

age, job, education, marital



Situazione finanziaria


balance, housing, loan, default



Storico contatti

contact, duration, month, campaign, pdays, previous, poutcome

Y: variabile target



■ No (88%) ■ Si (12%)



METODOLOGIA

Split del dataset

Lo split è stato eseguito prima di calcolare qualsiasi statistica, per evitare data leakage tra train e test.

TRAIN 80%

36.223 righe

TEST 20%

8.988 righe



Split 80/20 con seed fisso (42), per risultati riproducibili



Media, moda e deviazione standard calcolate solo sul train



Dataset puliti salvati come tabelle Delta nel Lakehouse



Analisi dei valori mancanti

Il dataset non contiene NaN in senso tecnico: le informazioni assenti sono segnate come testo “unknown”, qui trattate come NaN.

Variabile	Unknown count	Unknown %
poutcome	29.560	81,73%
contact	10.385	28,71%
education	1.483	4,10%
job	233	0,64%

poutcome è “unknown” nell'81,7% dei casi: non è un dato mancante a caso, ma il segnale che il cliente non era mai stato contattato prima.

education e job: “unknown” imputato con la moda, calcolata per gruppo in base al lavoro del cliente.



Analisi dei valori estremi

Presenza di outliers, dovuta al fatto che alcune variabili presentano una distribuzione fortemente sbilanciata (metodo IQR).


Colonna	Q1	Q3	IQR	Lower	Upper	Outliers	%
pdays	-1,0	-1,0	0,0	-1,0	-1,0	6.612	18,28
previous	0,0	0,0	0,0	0,0	0,0	6.612	18,28
balance	70,0	1.429,0	1.359,0	-1.968,5	3.467,5	3.788	10,47
duration	103,0	318,0	215,0	-219,5	640,5	2.589	7,16
campaign	1,0	3,0	2,0	-2,0	6,0	2.467	6,82
age	33,0	48,0	15,0	10,5	70,5	390	1,08
day	8,0	21,0	13,0	-11,5	40,5	0	0,00

I valori “anomali” di pdays e previous non sono veri outlier statistici: riflettono il codice convenzionale -1/0 dei clienti mai contattati prima, gestito con feature engineering anziché rimozione.



CORRELAZIONI

Cosa influenza la scelta del cliente?



duration è il fattore più legato a y (0,39), seguito da poutcome (0,31) e month (0,26).

duration non viene usata nei modelli: si conosce solo a chiamata conclusa, quando la decisione è già presa (data leakage).

pdays e poutcome sono fortemente legate tra loro (0,88): codificano entrambe lo storico di contatto del cliente.



PREPARAZIONE DEI DATI

Pre-processing e Features engineering



Rimossi i contatti duplicati



“Unknown” imputato con la moda, calcolata per gruppo (job)



Log transform a segno preservato su balance, per ridurre l'asimmetria



Standardizzazione z-score delle variabili quasi continue (solo sul train)



Encoding binario (yes/no) e one-hot k-1 per le categoriali multiclasse



previous_contacted

Vale 1 se previous > 0, 0 altrimenti



recall

Vale 1 se pdays > -1, 0 altrimenti


+ 2 nuove feature per lo storico contatti



IMPORTANZA DELLE VARIABILI

Cosa guarda di più il modello

Le 8 variabili più rilevanti per RandomForest_Tuned (duration esclusa per data leakage).



Variabili più importanti

contact_unknown, pdays, age, housing e balance pesano più di tutte le altre variabili messe insieme.

Le feature create funzionano

recall e previous_contacted, costruite ad hoc, entrano comunque tra le variabili più rilevanti.




RISULTATI

Metriche di validazione

Target sbilanciato (88% no / 12% sì): guidiamo la scelta con il ROC-AUC. Modello scelto: RandomForest_Tuned.

Modello	Acc.	Prec.	Rec.	F1	ROC-AUC
RandomForest_Tuned	0,80	0,32	0,59	0,42	0,77
DeepLearning_Keras	0,79	0,31	0,58	0,40	0,76
XGBoost_Tuned	0,74	0,26	0,65	0,37	0,76
SVM	0,76	0,28	0,60	0,38	0,75
XGBoost	0,79	0,30	0,57	0,39	0,75
RandomForest	0,88	0,55	0,16	0,25	0,75
LogisticRegression	0,72	0,25	0,65	0,36	0,75
KNN	0,88	0,47	0,18	0,26	0,68
DecisionTree	0,82	0,25	0,25	0,25	0,57



Curva ROC — RandomForest_Tuned (AUC = 0,769)



Sviluppi Futuri



Oltre la singola banca

Validare il modello su dataset di altre banche e contesti geografici, per verificare che i pattern individuati non siano specifici del Portogallo.



Ensamble di modelli

Combinare le probabilità predette da modelli di natura diversa, tramite soft voting, sfruttando il fatto che modelli con bias differenti tendono a commettere errori scorrelati.



GRAZIE PER L'ATTENZIONE

Cerea Gianluca · Andrea Morlotti