


Life Expectancy WHO

ANALISI DATASET KAGGLE

Gruppo: CereaMorlotti

Autori:

- Morlotti Andrea
- Cerea Gianluca



Scelta del Dataset

Abbiamo ricevuti dei requisiti operazionali per la scelta del Dataset, che abbiamo pienamente rispettato.

L'obiettivo della nostra analisi è predire l'aspettativa di vita con variabile target `life_expectancy`, tramite indicatori sanitari ed economici

Requisito	Valore	Esito
Dimensione minima (500 righe)	2938 righe	✓
Feature predittive (≥ 5)	19 usate nei modelli	✓
Mix numeriche e categoriali	Numeriche + status	✓
Valori mancanti presenti	population 22%, hepatitis_b 19%	✓
Sorgente pubblica citabile	Kaggle / OMS, licenza Open	✓



2938

osservazioni




2000-2015

periodo





193

paesi




EDA

L'analisi esplorativa iniziale è stata svolta sul dataset raw iniziale per evitare qualsiasi data leakage sul train




Imputazione dei Missing



Population: 22% missing +
correlazione quasi nulla ($r=0.02$) →
rimossa

I missing sono stati inputati tramite
Mediana per gruppo status
(Developed/Developing) poichè la
distribuzione di molte variabili era
fortemente asimmetrica
Le mediane vengono calcolate sul
dataset raw

Colonna	Missing %	Strategia
population	22.19%	Rimossa ($r=0.02$ con target)
hepatitis_b	18.82%	Mediana per gruppo status
gdp	15.25%	Mediana per gruppo status
total_expenditure	7.69%	Mediana per gruppo status
alcohol	6.60%	Mediana per gruppo status
income_composition	5.68%	Mediana per gruppo status
schooling	5.55%	Mediana per gruppo status



Modelli Sviluppati

Sono state scelte famiglie di modelli molto diverse tra loro, per confrontare approcci con logiche differenti e capire quale si adatta meglio ai dati: modelli lineari come baseline, un albero singolo, ensemble bagging e boosting, una rete neurale e uno strumento di AutoML. Confrontare modelli così eterogenei permette di verificare se il problema richiede modelli complessi o se anche approcci semplici sono sufficienti. In totale sono stati sviluppati e confrontati 10 modelli








Modelli Lineari	Alberi & Ensemble	Avanzati
☐ Linear Regression	☒ Decision Tree	☒ Deep Learning Keras
☐ Ridge	☐ Random Forest	
☐ Lasso	☒ Gradient Boosting	☐ AutoML FLAML
	☐ RF Tuned	
	☐ GB Tuned	

Analisi delle Performance dei modelli

Modello	RMSE	MAE	R ²	Adj R ²	MSE
RandomForest Tuned	1.627	1.079	0.970	0.969	2.645
GradientBoosting Tuned	1.640	1.090	0.969	0.968	2.689
RandomForest	1.679	1.100	0.968	0.967	2.821
GradientBoosting	2.131	1.560	0.948	0.946	4.542
AutoML (LightGBM)	2.138	1.565	0.947	0.946	4.571
DecisionTree	2.668	1.642	0.918	0.916	7.120
DeepLearning Keras	3.300	2.466	0.875	0.871	10.893
LinearRegression	3.877	2.832	0.827	0.822	15.033
Ridge	3.883	2.835	0.827	0.821	15.077
Lasso	4.366	3.151	0.781	0.774	19.059

- Ensemble di modelli performano meglio perchè sono bravi a catturare relazioni non lineari
- AutoML trova tra i modelli disponibili i migliore
- Decision Tree performa in modo intermedio ma fa overfitting
- Keras-Reti neurali, il dataset è troppo piccolo per costruire un vantaggio evidente
- I modelli lineari non riescono a spiegare bene la distribuzione come gli altri modelli

Feature Importance



Esiste target leakage?




NO

adult_mortality e hiv_aids sono determinanti causali diretti, raccolti indipendentemente dall'OMS attraverso i registri di stato civile, non derivati dal dal tal target

Conclusione sui dati

- L'aspettativa di vita è determinata soprattutto da indicatori sanitari diretti (hiv_aids, adult_mortality), più che da indicatori economici generali (gdp, status)
- I modelli ensemble superano nettamente i modelli lineari (R^2 0.97 vs 0.83), confermando relazioni non lineari nel dataset
- Il tuning degli iperparametri ha migliorato le performance: Random Forest Tuned raggiunge $R^2 = 0.970$, il risultato migliore
- La rimozione degli outlier IQR si è rivelata controproducente: eliminava dati reali (epidemie, paesi ad alta mortalità) peggiorando tutti i modelli
- AutoML (LightGBM) ha raggiunto il livello del Gradient Boosting base ma non ha superato gli ensemble ottimizzati manualmente
- Il Deep Learning (Keras, $R^2 = 0.875$) performa peggio degli ensemble su questo dataset tabulare di dimensioni moderate



Sviluppi Futuri

- Testare XGBoost come alternativa al Gradient Boosting nativo
- Includere feature temporali per catturare trend annuali per paese
- Sperimentare la trasformazione logaritmica su hiv_aids, measles e under_five_deaths invece della rimozione outlier
- Utilizzare un validation set separato per la scelta finale del modello, mantenendo il test set unicamente per la valutazione conclusiva

